

Машинное обучение. Вводная лекция.

Московский физико-технический институт, МФТИ

Москва

Этапы развития области искусственный интеллект


- Предыстория (мечты об ИИ и теоретические основы алгоритмистики);
- Появление самообучающихся машин конец 50х, начало 60х;
- Системы основанные на знаниях 70е;
- Первые нейронные сети (в основе алгоритм обратного распространения ошибки) начало 80х;
- Прорыв связанный с применением глубокого обучения в 2006г;

Причины бурного развития ИИ: глубокое обучение, вычислительные мощности, большие наборы качественных данных.

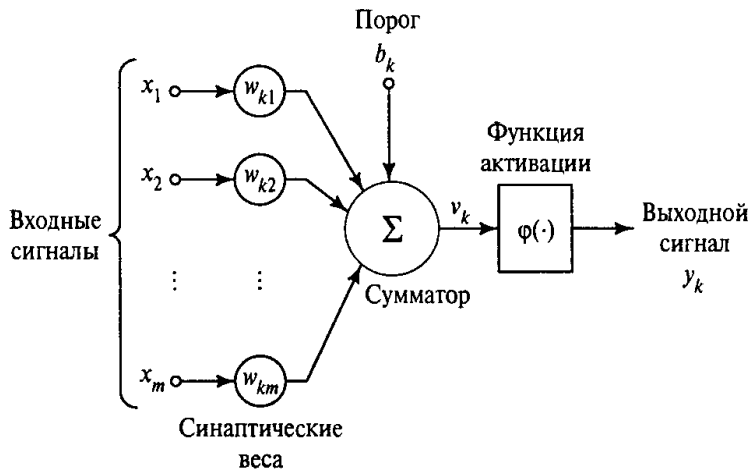
Модель МакКаллока-Питтса

Линейный классификатор или персептрон является простейшей математической моделью нервной клетки- нейрона. Нейрон имеет множество разветвлённых отростков - дендритов, и одно длинное тонкое волокно - аксон, на конце которого находятся синапсы, примыкающие к дендритам других нервных клеток. Нервная клетка может находиться в двух состояниях: обычном и возбуждённом. Клетка возбуждается, когда в ней накапливается достаточное количество положительных зарядов. В возбуждённом состоянии клетка генерирует электрический импульс величиной около 100 мВ и длительностью около 1 мс, который проходит по аксону до синапсов.

Картинка нейрона



Мат модель нейрона



От нейрона к нейросетям

Тринадцатая проблема Гилберта решена Колмогоровым в 1957 году:

Теорема

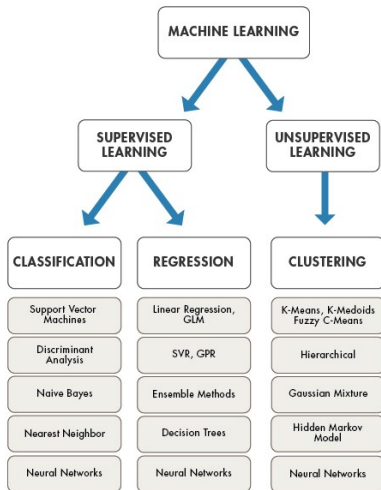
Любая непрерывная n аргументов на единичном кубе $[0, 1]$ представима в виде суперпозиции непрерывных функций одного аргумента и операции сложения:

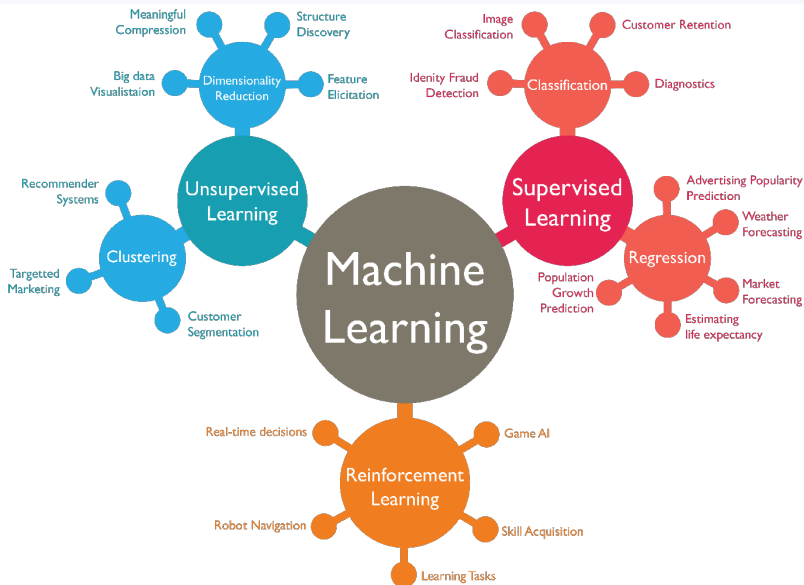
*$$f(x^1, x^2, \dots, x^n) = \sum_{k=1}^{2n+1} h_k \left(\sum_{i=1}^n \varphi_{ik}(x^i) \right),$$
 где h_k, φ_{ik} непрерывные функции, причем φ_{ik} не зависят от выбора f .*

Нетрудно видеть, что записанное здесь выражение имеет структуру нейронной сети с одним скрытым слоем из $2n+1$ нейронов. Таким образом, двух слоёв уже достаточно, чтобы вычислять произвольные непрерывные функции, и не приближённо, а точно.

Различные виды нейросетей


- классические архитектуры: светрочные сети и автокодировщики, рекуррентные сети;
- порождающие состязательные сети;
- нейронные сети с подкреплением - привели к значительным прорывам;
- нейробайсовские методы - соединили нейронные сети и классический вероятностные вывод с помощью вариационных приближений;






Решаемые задачи


Classification



Regression



Clustering



Классификация

Регрессия

Кластеризация

Математические обозначения

Пусть задано множество объектов X и множество допустимых ответов Y . Исследуемый процесс описывается целевой функцией $y^* : X \rightarrow Y$, задано конечное множество объектов $\{x_1, \dots, x_l\} \subset X$. Пары объектов $X^l = (x_i, y_i)_{i=1}^l$ представляют собой обучающую выборку.

Основная задача состоит в восстановлении зависимости y^* , а именно в построении **решающей функции** $a : X \rightarrow Y$, причем на всем множестве X .

Решаются следующие вопросы

- как задаются объекты и какими могут быть ответы (представление данных);
- в каком смысле $a(x)$ приближает $y(x)$ (выбор нормы);
- правило построения $a(x)$;
- $\mathbb{Y} = \{0, 1\}$ бинарная классификация;
- $\mathbb{Y} = \{1, \dots, K\}$ - многоклассовая классификация;
- $\mathbb{Y} = \{0, 1\}^K$ - многоклассовая классификация с пересекающимися классами;

Методика обучения

В качестве **модели алгоритма** рассмотрим функцию $g(x, \theta) : X \times \Theta \rightarrow Y$, где Θ множество допустимых значений параметра.

$$g(x, \theta) = \sum_{j=1}^n \theta_j f_j(x), \quad Y = \mathbb{R}$$

$$g(x, \theta) = \text{sign} \sum_{j=1}^n \theta_j f_j(x), \quad Y = \{-1, +1\}$$

Метод обучения - это отображение $\mu : (X \times Y)^l \rightarrow A$, которое произвольной коеченой выборке ставит некоторый алгоритм.

Функционал качества

$$Q(a, X^I) = \frac{1}{I} \sum_{i=1}^I \mathcal{L}(a, x_i).$$

- $\mathcal{L}(a, x_i) = [a(x) \neq y^*(x)]$ - индикатор ошибки,
- $\mathcal{L}(a, x_i) = |a(x) - y^*(x)|$ - отклонение от правильного ответа;
- $\mathcal{L}(a, x_i) = (a(x) - y^*(x))^2$ - квадратичная функция потерь;

Иными словами задача восстановления регрессии есть не что иное, как метод наименьших квадратов

$$\mu(X^I) = \arg \min_{\theta} \sum_{i=1}^I (g(x_i, \theta) - y_i)^2,$$

Принцип максимума правдоподобия

Вместо модели алгоритма $g(x, \theta)$, аппроксимирующей $y^*(x)$ зададим модель совместной плотности распределения объектов и ответов $\varphi(x, y, \theta)$.

В случае независимой последовательности наблюдений $p(X^I) = p(x_1, y_1) \dot{p}(x_I, y_I)$, получаем функцию правдоподобия

$$L(\theta, X^I) = \prod_{i=1}^I \varphi(x_i, y_i, \theta).$$

[Пример с нормальным распределением и средней дисперсией]

Оценки обучающей способности

- Эмпирический риск на тестовых данных

$$HO(\mu, X^l, X^k) = Q(\mu(X^l), X^k) \rightarrow \min,$$

- Кросс-проверка, $L = l + k$, $X^L = X_n^l \sqcup X_n^k$:

$$CV(\mu, X^L) = \frac{1}{|N|} \sum_{n \in N} Q(\mu(X_n^l), X_n^k) \rightarrow \min,$$

- Эмпирическая оценка вероятности переобучения:

$$Q_\varepsilon(\mu, X^L) = \frac{1}{|N|} \sum_{n \in N} \left[Q(\mu(X_n^l), X_n^k) - Q(\mu(X_n^l), X_n^l) \geq \varepsilon \right] \rightarrow \min$$

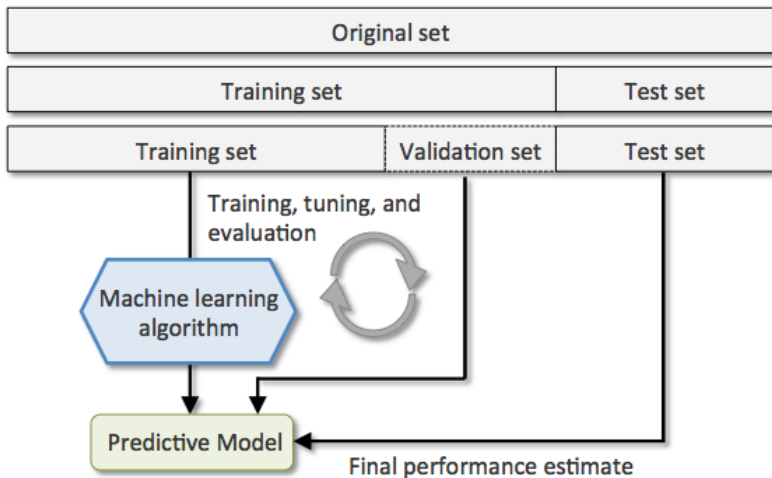
Кросс-проверка

Выборку $X^L = (x_i, y_i)_{i=1}^l$ разобьем N различными способами.

Для каждого разбиение $n = 1..N$ построим алгоритм $a_n = \mu(X_n^l)$ и вычислим среднее значение ошибки $Q_n = Q(a_n, X_n^k)$. Среднее арифметическое невязок всех указанных алгоритмов называется **скользящим контролем**


$$CV(\mu, X^L) = \frac{1}{N} \sum_{n=1}^l Q(\mu(X_n^l), X_n^l).$$

Скользящий контроль. Иллюстрация.




Переобучение


learning & regularization



Underfitting



Overfitting



Balanced

ДЗЗ изучения растительного покрова

Особое место среди попиксельной классификации занимают методы машинного обучения: классификация с использованием самоорганизующихся нейронных сетей, деревьев решений, опорных векторов. **Нейронные сети** более всего подходят для объектов с нечеткими границами.

Деревья решений здесь в отличие от "черного ящика" нейронных сетей можно указать, какие показатели использованы для разделения на классы (так называемые "ключи")

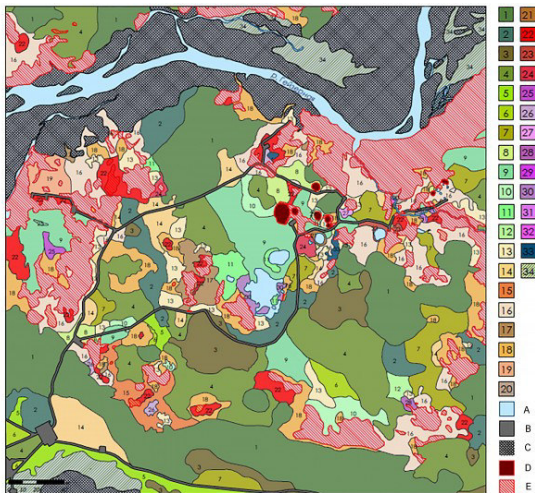


Рис. 1. Растительность Долины р. Гейзерной:

1 – каменоберезняк разнотравный, 2 – ивняк шеломайниковый, 3 – сообщества ольхового стланика, 4 – крупнотравно-шеломайниковые луговые сообщества, 5 – высокотравные луговые сообщества с преобладанием лабазника и бодяка, 6 – высокотравные луговые сообщества с преобладанием вол-








Рисунок 5. Варианты темновойных лесов хорошо разделяются в пространстве спектральных и морфометрических признаков методом дискриминантного анализа (цифрами обозначены синтаксоны в соответствии с таблицей 1)

Таблица 1. Сообщества темнохвойных лесов Северо-Западного Кавказа. В правом столбце – нумерация синтаксонов, используемая в дальнейшем обсуждении

Cl. <i>Carpino-Fagetia sylvaticae</i> Jakucs ex Passarge 1968	
Or. <i>Rhododendro pontici</i> - <i>Fagetalia orientalis</i> (Soó 1964) Pass. 1981	
Al. <i>Abieti-Fagion orientalis</i> Korotkov et Belonovskaja 1987	
Subal. <i>Abieti-Fagenion orientalis</i> Korotkov et Belonovskaja 1987	
Ass. <i>Ilici colchicae</i> – <i>Abietetum nordmannianae</i> Korotkov et Belonovskaja 1987	
Subass. <i>I. c.</i> – <i>A. n. vaccinietosum arctostaphyli</i> Belonovskaja et al 1990	2
Subass. <i>I. c.</i> – <i>A. n. rhododendretosum pontici</i> Belonovskaja et al 1990	1
Ass. <i>Abieti</i> – <i>Fagetum orientalis</i> Korotkov et Belonovskaja 1987	
Subass. <i>A.</i> – <i>F. o. piceetosum orientalis</i> Belonovskaja et al 1990	
Var. <i>Luzula sylvatica</i>	3
Var. <i>Calamagrostis arundinacea</i>	4
Var. ≡ Ass. <i>Petasito albae</i> - <i>Abietetum nordmannianae</i> Frantsuzov 2006	5
Var. <i>Salvia glutinosa</i>	6
Subass. <i>A.</i> – <i>F. o. athyrietosum filici-feminae</i> Belonovskaja et al 1990	
Var. <i>Galeobdolon luteum</i>	7
Var. <i>Sanicula europaea</i>	8

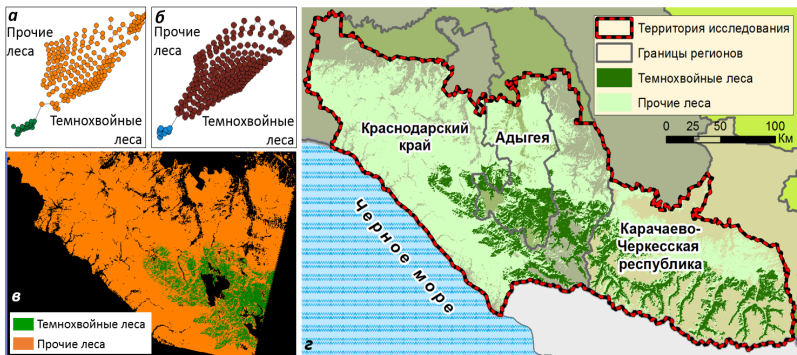


Рисунок 8. Картографирование темнохвойных лесов. а, б – структура нейронных сетей, построенных независимо по разным снимкам; в – результат классификации снимка нейронной сетью; г – конечный результат

Заключение

1. Анализ предметной области;
2. Коррекция данных, формализация признаков;
3. Построение прямой мат модели;
4. Подбор невязки, решение задачи оптимизации;
5. Поиск оптимального решения, регуляризация решения;
6. Оценки качества полученной модели;
7. Тестирование модельное и аппробация;