

# Машинное обучение. Линейная классификация.

Московский физико-технический институт, МФТИ

Москва

## План лекции

1. Линейная модель классификации;
2. Логистическая регрессия;
3. Метод опорных векторов;
4. Метрики качества классификации;

## Основные понятия и обозначения

*Дано:* выборка обучающих пар объектов  $X^I = (x_i, y_i)'_{i=1}$ .

В общем виде алгоритм классификации представим функцией  $a(x, w) = \text{sign } f(x, w)$ . *Задача:* найти разделяющую поверхность  $f(x, w) = 0$ . **Отсутпом объекта** называется величина  $M_i(w) = y_i f(x_i, w)$  относительно алгоритма классификации  $a(x, w)$ .

## Аппроксимация эмпирического риска

Пусть  $\phi$  - монотонно невозрастающая функция отсупа, мажорирующую функцию потерь  $[M < 0] \leq \mathcal{L}(M)$ .

$$Q(w, X^l) = \sum_{i=1}^l [M_i(w) < 0] \leq \tilde{Q}(w, X^l) = \sum_{i=1}^l \phi(M_i(w)) \rightarrow \min_w.$$

$$Q(M) = (1 - M)^2$$

- квадратичная,

$$V(M) = \max\{0, 1 - M\}$$

- кусочно-линейная,

$$S(M) = 2/(1 + e^{-M})$$

- сигмоидная,


$$L(M) = \ln_2(1 + e^{-M})$$

- логистическая,

$$E(M) = e^{-M}$$

- экспоненциальная.

## Аппроксимация пороговой функции



## Мат модель линейной классификации

Рассмотрим классифицирующие модели вида  $a(x, w) = \text{sign } f(x, w)$ , так что множество значений функционала  $Y = \{-1, +1\}$ . Функция доли неправильных ответов

$$Q(a, x) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i] = \frac{1}{l} \sum_{i=1}^l [\text{sign} \langle w, x_i \rangle \neq y_i] \rightarrow \min_w,$$

или в более компактной записи

$$Q(a, x) = \frac{1}{l} \sum_{i=1}^l [y_i \langle w, x_i \rangle < 0]$$

положим  $M_i = y_i \langle w, x_i \rangle$ .

## Вероятностная модель данных

Применим метод *максимума правдоподобия*. Пусть все наблюдения **независимы**, каждое из которых описывается функцией распределения  $p(x, y|w)$ , тогда правдоподобие выборки можно представить  $p(X^I|w) = \prod_{i=1}^I p(x_i, y_i|w) \rightarrow w$ , так что указанный метод эквивалентен постановке минимизации ошибок или функции потерь

$$-\sum_{i=1}^I \ln p(x_i, y_i|w) \mathcal{L}(y_i f(x_i, w)).$$

## Базовые предположения

### Предположение

Множество прецедентов  $X \times Y$  является вероятностным пространством. Выборка прецедентов  $X^I = (x_i, y_i)_{i=1}^I$  получена случайно и независимо согласно вероятностному распределению с плотностью  $p(x, y) = P_y p_y(x) = P(y|x)p(x)$ , где  $P_y$ - априорные вероятности,  $p_y$  - функции правдоподобия,  $P(y|x)$  - апостериорные вероятности классов  $y \in Y$ .

### Предположение

Функции правдоподобия классов принадлежат экспоненциальному семейству плотностей, имеют равные значения параметров  $d$  и  $\delta$ , но отличаются значениями параметров сдвига  $\theta_y$ .



$$accuracy = \frac{TP + TN}{TP + FP + FN + TN},$$

$$precision = \frac{TP}{TP + FP},$$

$$recall = \frac{TP}{TP + FN},$$

Критерий качества на основе точности и полноты: F - мера, гармоническое среднее точности и полноты:

$$F = \frac{2 * precision * recall}{precision + recall}$$

## Площадь под ROC -кривой

Доли неверно принятых объектов (False Positive Rate) и верно принятых объектов (True Positive Rate)

$$FPR = \frac{FP}{FP + TN},$$

$$FPR = \frac{TP}{TP + FN}.$$

Проблема чувствительности к соотношению классов -> решение через precision-recall кривая оценки.

## Пример ROC -кривой

